

计算机视觉期末作业：2DGS/AIGC 场景融合与 LeRobot ACT 泛化

阎丞麟 23307110060

潘艺赫 23307110090

2026 年 6 月

GitHub 仓库: `TODO_PUBLIC_REPOSITORY_URL`

模型权重与视频下载: <https://drive.google.com/drive/u/0/folders/1w051nD2L4Q1x61wkvZTFGSNTZrD8LX>

1 任务背景与数据集

本文完成两个任务：基于 2DGS 与 AIGC 的多源 3D 资产生成和真实场景融合，以及基于 LeRobot ACT 的 CALVIN 跨环境泛化实验。CALVIN 数据使用 `xiaoma26/calvin-lerobot`，其中 `splitB` 用于基础模型训练，`splitA+B+C` 用于多环境联合训练，`splitD` 仅用于 zero-shot 测试。

2 题目一：2DGS 与 AIGC 场景融合

2.1 方法

物体 A 使用手机多视角图像 (28 张)、COLMAP 位姿估计和 2DGS 重建 (4000 iterations); 物体 B 使用 threestudio 从文本 prompt "a cute toy robot, high quality, 3d model" 生成 3D 资产; 物体 C 使用 Magic123 从单张去背景图像 (3000 steps coarse mesh) 生成 3D 资产; 背景使用 Mip-NeRF 360 的 counter 场景进行 2DGS 重建。

2.2 统一表示与融合

不同方法输出的表示包括高斯点、mesh 与纹理 mesh。实验中将资产导出或采样为包含 `x y z red green blue` 的 ASCII PLY，并通过尺度、旋转和平移参数对齐到同一场景坐标系。融合参数记录于 `configs/fusion_transforms.example.json`，包含各物体的 `scale`、`rotation` 和 `translation` 向量。

由于各资产生成方法的输出格式差异 (2DGS 输出高斯点、threestudio 输出 mesh、Magic123 输出 mesh)，我们统一将资产采样为点云 PLY 格式进行融合。漫游视频通过 `render_fusion_pointcloud.py` 脚本采用点云投影渲染方式生成 (24 秒，1280×720 分辨率，24fps)。

2.3 结果与分析

资产	方法	顶点/高斯数	纹理细节	备注
物体 A	多视角 2DGS	约 150K 高斯	高（真实照片）	28 张图像，4000 iter
物体 B	文本到 3D	约 50K 顶点	中（文生纹理）	threestudio DreamFusion
物体 C	单图到 3D	约 100K 顶点	中高（参考图）	Magic123 coarse mesh
背景	2DGS	约 300K 高斯	高（Mip-NeRF 360）	counter 场景
融合场景	点云合并	615,609 顶点	综合	统一坐标系对齐

表 1: 三种资产生成方式和背景重建对比。

关键帧截图：图 1 展示了融合场景的 6 个关键帧，包括视角漫游过程中的不同角度。




图 1: 融合场景漫游视频关键帧（24 秒漫游，1280×720 分辨率）。

渲染方式说明：由于融合场景包含多种格式的 3D 资产（高斯点云、mesh），直接使用 Blender 渲染需要复杂的材质转换。本实验采用点云投影渲染方式：将 mesh 采样为点云，与 2DGS 高斯点统一为 PLY 点云格式，使用 Open3D 进行视角变换和投影渲染。这种方式保留了各资产的视觉特征，生成的视频亮度正常（关键帧平均亮度约 15-16）。

3 题目二：LeRobot ACT 跨环境泛化

3.1 实验设置

项目	Baseline (env_b)	Joint (env_abc)
Policy	ACT	ACT
Batch size	8	8
Learning rate	1e-5	1e-5
Optimizer	AdamW	AdamW
Weight decay	1e-4	1e-4
Training steps	50,000	50,000
Action chunk size	100	100
Hidden dim	512	512
Dim feedforward	3200	3200
Encoder layers	4	4
Decoder layers	1	1
KL weight	10.0	10.0
Num workers	4	4
Seed	42	42

表 2: ACT 超参数设置。两模型使用完全相同的网络架构和训练超参数，唯一变量为训练数据 (splitB vs splitA+B+C)。

3.2 结果

模型	训练环境	splitD Action L1 ↓	splitD Action MSE ↓	测试批次
Baseline	B	0.650	0.889	381
Joint	A+B+C	0.564	0.725	254

表 3: 环境 D zero-shot 离线评测结果 (50 episodes)。

Success Rate 说明：离线评测 `eval_act_offline.py` 仅能计算 action 误差 (L1/MSE)，无法直接得到 Success Rate。Success Rate 需要在仿真环境或真实机器人上执行 rollout 并检测任务完成情况才能获取。本实验目前仅提供 action 误差指标，已优于基线 (Joint 模型的 Action L1 比 Baseline 低 13.2%)。

3.3 Action Chunking 分析

ACT 的动作分块 (Action Chunking) 机制通过一次性预测未来 T 个时间步的动作序列 (本实验 $T = 100$)，而非单步预测，具有以下特点：

1. 降低短期噪声：动作分块通过自回归解码器生成平滑的动作序列，可以有效滤除单步预测的随机噪声。在多环境联合训练中，不同环境的数据分布差异 (如物体位置、相机角度) 会引入

额外的动作噪声, Chunking 机制通过序列建模保持了动作的一致性。

2. 视觉误差累积问题: 长动作块 ($T = 100$) 虽然提高了短期动作连贯性, 但也放大了视觉误差累积。当机器人在未见过的环境 D 执行时, 前几步的微小视觉估计误差会在后续动作中累积。实验结果显示, 联合模型在 splitD 上的 Action L1 (0.564) 优于基线 (0.650), 说明多环境训练提高了视觉特征的泛化能力, 从而改善了 chunk 内动作的一致性。

3. 多环境训练的收益: 训练于 A+B+C 的联合模型在 zero-shot 测试 splitD 时 action 误差更低, 验证了跨环境训练对泛化的正面作用。多环境数据引入了视觉分布偏移 (不同环境的光照、物体、背景), 使模型学习到更鲁棒的视觉-动作映射, 减少了在新环境中的视觉估计误差。

3.4 训练曲线分析




图 2: ACT 训练 total loss 曲线。两模型均训练 50,000 steps; 曲线由本地训练日志每 200 steps 的 loss 字段重建, 浅色为原始记录, 深色为滑动平均。




图 3: splitD 离线验证指标曲线。上图为 Action L1，下图为 Action MSE；浅色为逐 batch 指标，深色为滑动平均，虚线为整体均值。

从曲线可以观察到：(1) 两个模型的 total loss 均快速下降并在后期趋于稳定，说明训练过程正常收敛；(2) Joint 模型在 splitD 上的 Action L1 与 Action MSE 均值低于 Baseline，说明多环境训练提升了 zero-shot 泛化能力；(3) 由于未开启在线记录和训练期验证，本实验的验证曲线为最终模型在 splitD 上的离线 batch-wise 指标，而非训练过程中的周期性 validation 曲线。

4 结论

题目一 (2DGS/AIGC 融合): 完成了多源 3D 资产生成 (真实 2DGS、文本生成 threestudio、单图生成 Magic123) 和场景融合，生成了 24 秒可漫游视频。主要局限包括：仅使用 counter 场景 (未包含 garden、bicycle)，物体 A 照片数量偏少，以及采用点云投影渲染而非 Blender 真实渲染。

题目二 (LeRobot ACT): 多环境联合训练 (A+B+C) 在 zero-shot 测试 splitD 上的 action 误差 (L1=0.564, MSE=0.725) 优于仅使用单环境 B 的基线模型 (L1=0.650, MSE=0.889)，验证了跨环境训练对策略泛化的积极作用。